

2.9 带松弛因子的SVM : C-SVM

CSDN学院
2017年11月



► 大纲



- SVM基本原理
- 带松弛因子的SVM：C-SVM
- 核方法
- 支持向量回归
- Scikit learn中的SVM实现
- 案例分析



- 之前我们讨论的是样本可以完全线性可分的情况，即

$$y_i (w_0 + \mathbf{w}^T \mathbf{x}_i) \geq 1$$

- 在实际问题中，数据不一定线性可分。因此解决方案引入**软间隔**（soft margin），允许一些样本出错，即允许某些样本不满足约束，将约束放松为


$$y_i (w_0 + \mathbf{w}^T \mathbf{x}_i) \geq 1 - \xi_i$$

- 其中 ξ_i 称为**松弛变量**（slack variables）
- 但不满足约束的样本越少越好，因此增加松弛量限制



$$\xi_i \geq 0, \sum_i \xi_i \leq C$$

▶ 数据不完全线性可分



- 因此软间隔的SVM (C-SVM) 目标函数为

$$\min \frac{1}{2} \|\mathbf{w}\|^2, \quad \text{subject to} \quad y_i (w_0 + \mathbf{w}^T \mathbf{x}_i) \geq 1 - \xi_i, \quad \forall i$$

- 且松弛变量 ξ_i 限制为 $\xi_i \geq 0, \sum_i \xi_i \leq C$ 。
- 可以将上公重写为

$$J(\mathbf{w}) = \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^N \xi_i$$

$$\text{subject to} \quad y_i (w_0 + \mathbf{w}^T \mathbf{x}_i) \geq 1 - \xi_i,$$

$$\xi_i \geq 0$$

- 目标函数：
$$J(\mathbf{w}) = \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^N \xi_i$$
$$\text{subject to } y_i (w_0 + \mathbf{w}^T \mathbf{x}_i) \geq 1 - \xi_i,$$
$$\xi_i \geq 0$$
- 其中参数 C 控制间隔和松弛变量惩罚项之间的平衡
- 被误分的点的 $\xi_i > 1$ ，因此 $\sum_i \xi_i$ 为被误分点的数目的上界，
可视为训练误差
- 因此参数 C 可视为控制最小训练误差和模型复杂度的参数

► C-SVM——对偶

- 目标函数：
$$\min \left[\frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^N \xi_i \right]$$

 subject to $y_i (w_0 + \mathbf{w}^T \mathbf{x}_i) \geq 1 - \xi_i,$
 $\xi_i \geq 0$

- 对应的拉格朗日函数为

$$L(\boldsymbol{\alpha}, \boldsymbol{\mu}, w_0, \mathbf{w}) = \frac{1}{2} \mathbf{w}^T \mathbf{w} + C \sum_{i=1}^N \xi_i - \sum_{i=1}^N \alpha_i (y_i (w_0 + \mathbf{w}^T \mathbf{x}_i) - 1 + \xi_i) - \sum_{i=1}^N \mu_i \xi_i$$

其中 $\alpha_i \geq 0, \mu_i \geq 0$ 为拉格朗日乘子。

► C-SVM——对偶

- 对拉格朗日函数求偏导数，得

$$\frac{\partial L}{\partial \mathbf{w}} = 0 \Rightarrow \mathbf{w}^* = \sum_{i=1}^N \alpha_i y_i \mathbf{x}_i$$

$$\frac{\partial L}{\partial w_0} = 0 \Rightarrow \sum_{i=1}^N \alpha_i y_i = 0$$

$$\frac{\partial L}{\partial \xi_i} = 0 \Rightarrow C = \alpha_i + \mu_i$$

► C-SVM——对偶

- 将结果代入拉格朗日函数，得到其对偶问题

$$Q(\alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j \langle \mathbf{x}_i, \mathbf{x}_j \rangle$$

- s.t. $\sum_{i=1}^N \alpha_i y_i = 0$

$$0 \leq \alpha_i \leq C$$

- 与线性可分情况的不同之处仅在于约束为 $0 \leq \alpha_i \leq C$
 - 线性可分情况 : $0 \leq \alpha_i$



最后的决策函数形式同线性可分情况

► C-SVM – KKT Conditions

$$\alpha_i \geq 0$$

$$y_i (w_0 + \mathbf{w}^T \mathbf{x}_i) - 1 + \xi_i \geq 0$$

$$\alpha_i \left[y_i (w_0 + \mathbf{w}^T \mathbf{x}_i) - 1 + \xi_i \right] = 0$$

$$\mu_i \geq 0$$

$$\xi_i \geq 0$$

$$\mu_i \xi_i = 0$$

► α 的稀疏性

$$\alpha_i \left[y_i (w_0 + \mathbf{w}^T \mathbf{x}_i) - 1 + \xi_i \right] = 0$$


- 与线性可分情况类似，一些数据点 $\alpha_i = 0$
 - 被正确分类，在支持超平面之外，对预测没有贡献
- 对 $\alpha_i > 0$ 的点，必须满足
$$y_i (w_0 + \mathbf{w}^T \mathbf{x}_i) = 1 - \xi_i$$
 - 若 $\alpha_i < C$ ，则 $\mu_i > 0, \xi_i = 0$ ，位于支持平面/边界上
 - 若 $\alpha_i = C$ ，则 $\xi_i \leq 1$ （位于支持平面/边界里面，或 $\xi_i > 1$ （被误分）

► 合页损失 (hinge loss)

- 在C-SVM中 ,
 - 当 $y_i (w_0 + \mathbf{w}^T \mathbf{x}_i) \geq 1, \xi_i = 0$
 - 其他点 : $\xi_i = 1 - y_i (w_0 + \mathbf{w}^T \mathbf{x}_i)$
- 因此目标函数 $C \sum_{i=1}^N \xi_i + \frac{1}{2} \|\mathbf{w}\|^2$
- 可写成 $\sum_{i=1}^N [1 - y_i (w_0 + \mathbf{w}^T \mathbf{x}_i)]_+ + \lambda \|\mathbf{w}\|^2 = \sum_{i=1}^N [1 - y_i \eta_i]_+ + \lambda \|\mathbf{w}\|^2$
- 其中 λ 起到 C 的作用。该损失函数称为 **Hinge Loss**

► 分类任务中的损失函数

- 0-1损失函数： $l_{0/1}(y, f(x)) = \begin{cases} 1 & yf(x) < 0 \\ 0 & \text{otherwise} \end{cases}$
 - 不连续，不易于优化计算
- Logistic损失（logloss）： $l_{\log}(y, f(x)) = \log(1 + \exp(-yf(x)))$
 - Logistic回归 / 多层感知机，可得到类别的概率
- 合页损失： $l_{\text{hinge}}(y, f(x)) = \max(0, 1 - yf(x))$
 - SVM、稀疏解、不能直接得到类别的概率
- 指数损失： $l_{\text{exp}}(y, f(x)) = \exp(-yf(x))$



► SVM：合页损失 + L2正则

- Recall：机器学习一般模型的目标函数为：

$$J(\theta) = \sum_{i=1}^N l(f(\mathbf{x}_i; \theta), y_i) + \Omega(\theta)$$

- 当损失函数取负log似然，正则项取L2时，得到L2正则的Logistic回归

$$J(\mathbf{w}) = \sum_{i=1}^N -[y_i \log(\mu_i) + (1 - y_i) \log(1 - \mu_i)] + \lambda \|\mathbf{w}\|_2^2$$

- 当损失函数取合页损失，正则项取L2正则，得到SVM：

$$J(\mathbf{w}, \lambda) = \sum_{i=1}^N L(y_i, f(\mathbf{x}_i; \mathbf{w})) + \lambda \|\mathbf{w}\|^2$$

THANK YOU



AI100