

## 2.10 核方法

CSDN学院  
2017年11月

## ► 大纲





- SVM基本原理
- 带松弛因子的SVM：C-SVM
- **核方法**
- 支持向量回归
- Scikit learn中的SVM实现
- 案例分析



## 核方法

- 前面我们假设数据是线性可分的，即存在一个超平面可将训练样本正确分类。但在实际任务中，原始样本空间也许并不存在一个超平面能将训练样本分开。

- 例如：



$$\mathbf{z} = \phi(\mathbf{x}) = (x_1^2, \sqrt{2}x_1x_2, x_2^2)$$

- 对这类问题，我们可以将原始空间映射到一个更高维空间，使得在这个特征空间数据线性可分。

## ► 核方法

- 令  $\phi(\mathbf{x})$  表示将  $\mathbf{x}$  映射后的特征向量，则在特征空间中划分超平面对应的模型可表示为

$$f(\mathbf{x}) = \mathbf{w}^T \phi(\mathbf{x}) + w_0$$

- 根据之前SVM的推导，

$$\min \left[ \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^N \xi_i \right]$$

$$\text{subject to } y_i (w_0 + \mathbf{w}^T \phi(\mathbf{x}_i)) \geq 1 - \xi_i,$$

$$\xi_i \geq 0$$

## ► 核方法——对偶

- 将结果代入拉格朗日函数，得到其对偶问题

$$\max_{\alpha} \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j \langle \phi(\mathbf{x}_i), \phi(\mathbf{x}_j) \rangle$$

- s.t.  $\sum_{i=1}^N \alpha_i y_i = 0$

$$0 \leq \alpha_i \leq C$$

- 由于特征空间维数很高（甚至无穷维），直接计算特征空间的点积通常是困难的。



解决方案：**核函数**  $k(\mathbf{x}_i, \mathbf{x}_j) = \langle \phi(\mathbf{x}_i), \phi(\mathbf{x}_j) \rangle$

## ► 核方法——对偶

- 利用核函数，可求解得到

$$\begin{aligned} f(\mathbf{x}) &= \mathbf{w}^T \phi(\mathbf{x}) + w_0 \\ &= \sum_{j=1}^N \alpha_j y_j \phi(\mathbf{x}_j)^T \phi(\mathbf{x}) + w_0 \\ &= \sum_{j=1}^N \alpha_j y_j k((\mathbf{x}_j, \mathbf{x})) + w_0 \end{aligned}$$

## ► 核技巧 ( Kernel Trick )

- 将问题变为对偶问题：只需计算点积，与特征的维数无关
  - 如在SVM中，最大化下列目标函数

$$Q(\alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j k(\mathbf{x}_i, \mathbf{x}_j)$$

- 高维空间中的点积可写成核(kernel)的形式
- 选定核函数，无需计算映射  $\phi(x)$  就可以计算点积
  - 如将SVM核化，目标函数为

$$Q(\alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j \langle \mathbf{x}_i, \mathbf{x}_j \rangle$$

- 预测为

$$f(\mathbf{x}) = \sum_{j=1}^N \alpha_j y_j k(\mathbf{x}_j, \mathbf{x}) + w_0$$

## ► 非直接方式构造核函数

- 一种核函数的构造方式是显式地定义一个特征映射  $\phi(\mathbf{x})$  , 将每个输入  $\mathbf{x}$  映射到  $\phi(\cdot)$
- 从而得到核函数的间接定义： $k(\mathbf{x}, \mathbf{x}') = \phi(\mathbf{x})^T \phi(\mathbf{x}')$ 
  - $\phi(\mathbf{x})$  称为基函数。



## ► 直接定义核函数

- 另一种可选的方式是直接定义核函数
- 此时需保证函数是有效核。在显式定义特征映射的情况下，核函数为特征空间（可能为无限维）中的内积

## ► 核函数

- 令  $\mathcal{X}$  为输入空间,  $k(\cdot, \cdot)$  是定义在  $\mathcal{X}^* \mathcal{X}$  上的对称函数, 则  $k$  是核函数的充要条件是对任意数据  $\mathcal{D} = \{\mathbf{x}_1, \dots, \mathbf{x}_N\}$  核矩阵  $\mathbf{K}$  总是半正定的:

$$\mathbf{K} = \begin{pmatrix} k(\mathbf{x}_1, \mathbf{x}_1) & \cdots & k(\mathbf{x}_1, \mathbf{x}_N) \\ \vdots & & \\ k(\mathbf{x}_N, \mathbf{x}_1) & \cdots & k(\mathbf{x}_N, \mathbf{x}_N) \end{pmatrix}$$

- 对于一个半正定核矩阵, 总是能找到一个与之对应的映射  $\phi$ 
  - 任何一个核函数都隐式定义了一个再生Hilbert空间

## ► 多项式核

- 多项式核:  $k(\mathbf{x}, \mathbf{x}') = (\gamma \mathbf{x}^T \mathbf{x}' + r)^M$

– 当  $M = 2, \gamma = 1, r = 1,$

$$\begin{aligned}(1 + \mathbf{x}^T \mathbf{x}')^2 &= (1 + x_1 x'_1 + x_2 x'_2)^2 \\ &= 1 + 2x_1 x'_1 + 2x_2 x'_2 + (x_1 x'_1)^2 + (x_2 x'_2)^2 + 2x_1 x'_1 x_2 x'_2\end{aligned}$$

$$\phi(\mathbf{x}) = [1, \sqrt{2}x_1, \sqrt{2}x_2, x_1^2, x_2^2, \sqrt{2}x_1 x_2]$$

– 当  $M = 1, \gamma = 1, r = 0,$  为线性核:

$$\phi(\mathbf{x}) = \mathbf{x},$$

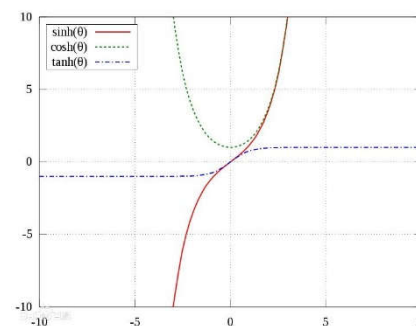
$$k(\mathbf{x}, \mathbf{x}') = \phi(\mathbf{x})^T \phi(\mathbf{x}') = \mathbf{x}^T \mathbf{x}'$$

## ► Sigmoid核

- 另一个核函数的例子是sigmoid核：

$$k(\mathbf{x}, \mathbf{x}') = \tanh(\gamma \mathbf{x}^T \mathbf{x}' + \theta)$$

- 其Gram矩阵通常不是p.s.d.
- 但在实际应用中有用到
  - 可能是因为其核展开形式（如SVM）与神经网络十分类似



## ► RBF核

- **平移不变核**:  $k(\mathbf{x}, \mathbf{x}') = \kappa(\mathbf{x} - \mathbf{x}')$
- 径向基函数 (RBFs)

$$k(\mathbf{x}, \mathbf{x}') = \kappa(|\mathbf{x} - \mathbf{x}'|) = \kappa(r)$$

- 指数平方(Squared exponential, SE)/**高斯核**

$$k(\mathbf{x}, \mathbf{x}') = \exp\left(-\frac{1}{2}(\mathbf{x} - \mathbf{x}')^T \Sigma^{-1}(\mathbf{x} - \mathbf{x}')\right)$$

- 当 $\Sigma$ 为对角阵时,  $k(\mathbf{x}, \mathbf{x}') = \exp\left(-\frac{1}{2} \sum_{j=1}^D \frac{(x_j - x'_j)^2}{\sigma_j^2}\right)$

- 当 $\Sigma$ 为球形时, 得到各向同性核:  $k(\mathbf{x}, \mathbf{x}') = \exp\left(-\frac{(\mathbf{x} - \mathbf{x}')^2}{2\sigma^2}\right)$ 
  - $\sigma$ 称为核函数的**带宽**

## ► 更多的核

- **核的闭包性质：** 令  $k_1$  &  $k_2$  为定义在  $X \times X$  核，则下列表示也是核：

$$k(\mathbf{x}, \mathbf{z}) = k_1(\mathbf{x}, \mathbf{z}) + k_2(\mathbf{x}, \mathbf{z})$$

$$k(\mathbf{x}, \mathbf{z}) = ak_1(\mathbf{x}, \mathbf{z})$$

$$k(\mathbf{x}, \mathbf{z}) = k_1(\mathbf{x}, \mathbf{z})k_2(\mathbf{x}, \mathbf{z})$$

$$k(\mathbf{x}, \mathbf{z}) = k_1(\phi(\mathbf{x}), \phi(\mathbf{z})), \text{ where } \phi: X \rightarrow \mathbb{R}^n$$

$$k(\mathbf{x}, \mathbf{z}) = \mathbf{x}^T \mathbf{B} \mathbf{z}, \text{ where } \mathbf{B} \text{ is SPD}$$

$$k(\mathbf{x}, \mathbf{z}) = p(k_1(\mathbf{x}, \mathbf{z})), \text{ where } p \text{ is a polynomial with positive coefficient}$$

$$k(\mathbf{x}, \mathbf{z}) = \exp(k_1(\mathbf{x}, \mathbf{z}))$$

$$k(\mathbf{x}, \mathbf{z}) = \exp(\|\mathbf{x} - \mathbf{z}\|^2 / 2)$$

## ► 小结：核方法

- 核函数应编码特征相似度的先验信息。
- 核函数的参数需要通过交叉验证选择或通过学习得到 (如 Multiple Kernel Learning).
- 非线性核有时能极大提高分类器的性能。
- 非线性核通常计算繁重（在训练和预测时）。

# THANK YOU



AI100