


2.11 支持向量回归 (SVR)

CSDN学院
2017年11月

► 支持向量回归

- 在之前的线性回归模型中，只有当 y 与 $f(\mathbf{x})$ 完全相等时，我们才认为损失为0（L2损失、L1损失、Huber损失）。
- 在支持向量回归中，我们能容忍 y 与 $f(\mathbf{x})$ 之间有 ϵ 的偏差，即当 y 与 $f(\mathbf{x})$ 之间的差异大于 ϵ 时才计算损失（ ϵ insensitive loss）。
 - 相当于以为中心，构造一个宽度为 2ϵ 的间隔带。若样本落入此间隔带，认为预测正确。



► SVM for 回归

- ε insensitive loss :

$$L_{\varepsilon}(y, \hat{y}) = \begin{cases} 0 & \text{if } |y - \hat{y}| < \varepsilon \\ |y - \hat{y}| & \text{otherwise} \end{cases}$$

– 误差较小时不惩罚


- 目标函数为

$$J(\mathbf{w}, \lambda) = \sum_{i=1}^N L_{\varepsilon}(y_i, \hat{y}_i) + \lambda \|\mathbf{w}\|^2$$

- 亦可写成

$$J(\mathbf{w}, C) = \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^N L_{\varepsilon}(y_i, \hat{y}_i)$$

– 为凸函数，但不可微



► SVM for 回归(cond.)

- 实际应用时，再加入松弛变量，用于表示每个点允许在 ε 管道外的程度

$$y_i \leq f(\mathbf{x}_i) + \varepsilon + \xi_i^+$$

$$y_i \geq f(\mathbf{x}_i) - \varepsilon - \xi_i^-$$

- 则目标函数变为

$$J(\mathbf{w}, C) = \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^N (\xi_i^+ + \xi_i^-)$$

- 约束为 $\xi_i^+ \geq 0, \xi_i^- \geq 0$

► SVM for 回归(cond.)

- 目标函数变为

$$J(\mathbf{w}, C) = \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^N (\xi_i^+ + \xi_i^-)$$

- 可以证明最优解为： $\hat{\mathbf{w}} = \sum_{i=1}^N \alpha_i \mathbf{x}_i$
- 预测为： $\hat{y}(\mathbf{x}) = \hat{w}_0 + \hat{\mathbf{w}}^T \mathbf{x} = \hat{w}_0 + \sum_{i=1}^N \alpha_i \mathbf{x}_i^T \mathbf{x}$
- 利用kernel trick 核化线性SVM：即用核函数 $k(\mathbf{x}_i, \mathbf{x})$ 代替点积 $\mathbf{x}_i^T \mathbf{x}$ ：

$$\hat{y}(\mathbf{x}) = \hat{w}_0 + \sum_{i=1}^N \alpha_i k(\mathbf{x}_i, \mathbf{x})$$

THANK YOU



AI100